



Predicción de Suscripción Bancaria Mediante Modelos de Aprendizaje Automático

Universidad Nacional del Altiplano - Escuela de Posgrado UNA PUNO

Milton Hiroshi Taco Aviles, Fabrizio Roy Choque Ormachea



RESUMEN

Este estudio presenta un enfoque de ciencia de datos para predecir la suscripción de clientes a depósitos bancarios mediante modelos de aprendizaje automático aplicados al conjunto de datos *Bank Marketing*.

Se desarrolló un flujo de análisis exploratorio, preprocesamiento, entrenamiento y evaluación de modelos. Se compararon dos algoritmos de clasificación supervisada: regresión logística y *Random Forest*.

Los resultados evidencian que *Random Forest* obtuvo el mejor desempeño, alcanzando un ROC-AUC de 0.9254 y un PR-AUC de 0.6073 en el escenario que incluye la variable *duration*.

INTRODUCCIÓN

Las campañas de telemarketing bancario suelen implicar altos costos operativos debido al gran número de contactos realizados y a las bajas tasas de conversión.

Los modelos predictivos permiten identificar clientes con mayor probabilidad de respuesta positiva, optimizando la asignación de recursos y mejorando la eficiencia comercial.

El problema abordado corresponde a una clasificación binaria: predecir si un cliente suscribirá o no un depósito a plazo.

OBJETIVO

Comparar el desempeño de modelos de aprendizaje automático para predecir la suscripción bancaria en campañas de marketing, evaluando el impacto de variables demográficas, financieras y de interacción telefónica.

Hipótesis: los modelos de ensamblaje, como *Random Forest*, presentan mayor capacidad predictiva que los modelos lineales tradicionales debido a su habilidad para capturar relaciones no lineales.

CONJUNTO DE DATOS

El conjunto de datos utilizado corresponde al repositorio *Bank Marketing*, asociado a campañas telefónicas realizadas por una institución bancaria portuguesa.

Variables principales:

- Edad del cliente
- Tipo de contacto
- Tipo de trabajo
- Duración de la llamada
- Estado civil
- Número de contactos previos
- Nivel educativo
- Resultado de campañas anteriores
- Balance financiero

Variable objetivo: suscripción o no suscripción de un depósito a plazo.

METODOLOGÍA

La investigación siguió un enfoque cuantitativo, experimental y aplicado. El flujo metodológico se estructuró en cinco etapas:

1. Análisis exploratorio de datos.
2. Identificación de valores atípicos y categorías unknown.
3. Codificación de variables categóricas mediante One-Hot Encoding.
4. Normalización de variables numéricas con *StandardScaler*.
5. Entrenamiento y evaluación de modelos supervisados.

Se empleó una división estratificada entre entrenamiento y prueba para conservar la proporción de clases.

DISEÑO EXPERIMENTAL

Se plantearon dos escenarios para evaluar el impacto de la variable *duration*:

Experimento 1: modelo accionable sin *duration*.

Excluye la duración de la llamada porque esta información solo se conoce después de contactar al cliente. Representa una aplicación más realista antes de la campaña.

Experimento 2: modelo benchmark con *duration*.

Incluye la duración de la llamada para estimar el máximo desempeño predictivo alcanzable.


Modelos evaluados: Regresión logística | *Random Forest*

Métricas utilizadas: Accuracy, Precision, Recall, F1-score, ROC-AUC y PR-AUC.

ANÁLISIS EXPLORATORIO

El análisis exploratorio mostró un desbalance considerable entre las clases, con predominio de clientes que no suscribieron el depósito.

Distribución de la variable objetivo



VARIABLES RELEVANTES

Se identificaron variables con relación importante con la respuesta del cliente. La variable *duration* presenta la mayor importancia.



RESULTADOS PRINCIPALES


Los resultados muestran que *Random Forest* obtuvo el mejor desempeño en ambos escenarios experimentales.

Experimento 1: sin duration						
Modelo	Acc.	Prec.	Recall	F1	ROC-AUC	PR-AUC
Reg. Logística	0.8660	0.52	0.31	0.39	0.7713	0.4087
Random Forest	0.8718	0.59	0.34	0.43	0.7999	0.4482


Experimento 2: con duration						
Modelo	Acc.	Prec.	Recall	F1	ROC-AUC	PR-AUC
Reg. Logística	0.8777	0.63	0.45	0.52	0.9079	0.5369
Random Forest	0.8893	0.69	0.51	0.58	0.9254	0.6073

✓ La inclusión de *duration* incrementó significativamente el rendimiento predictivo, especialmente en ROC-AUC y PR-AUC.

COMPARACIÓN DE MODELOS (CURVAS ROC)



EVALUACIÓN FRENTE AL DESBALANCE (CURVAS PR)



CONCLUSIONES

- ✓ Los modelos de aprendizaje automático son herramientas útiles para optimizar campañas de marketing bancario.
- ✓ *Random Forest* obtuvo el mejor desempeño global, con ROC-AUC de 0.9254 y PR-AUC de 0.6073.
- ✓ La variable *duration* es altamente predictiva, pero presenta limitaciones prácticas para decisiones antes de la llamada.
- ✓ El modelo sin *duration* representa un escenario más realista para la segmentación previa de clientes.
- ✓ La evaluación mediante ROC-AUC y PR-AUC permitió analizar mejor el desempeño frente al desbalance de clases.

REFERENCIAS

- [1] L. Breiman, "Random Forests," *Machine Learning*, 2001.
- [2] S. Moro, P. Cortez y P. Rita, "A Data-Driven Approach to Predict the Success of Bank Telemarketing," *Decision Support Systems*, 2014.
- [3] M. Kuhn y K. Johnson, *Applied Predictive Modeling*. Springer, 2013.
- [4] D. Hosmer, S. Lemeshow y R. Sturdivant, *Applied Logistic Regression*. Wiley, 2013.