

Análisis Exploratorio y Estadística Descriptiva del Conjunto de Datos Bank Marketing para la Predicción de Suscripción Bancaria

Fabrizio Roy Choque Ormachea
Maestría en Ciencia de Datos
Universidad Nacional del Altiplano Puno
Puno, Perú
20181167@lamolina.edu.pe

Milton Hiroshi Taco Aviles
Maestría en Ciencia de Datos
Universidad Nacional del Altiplano Puno
Puno, Perú
htacoav@gmail.com

Resumen—Este trabajo presenta un análisis exploratorio exhaustivo del conjunto de datos *Bank Marketing* del repositorio UCI, recopilado a partir de campañas de marketing telefónico realizadas por una institución bancaria portuguesa. El estudio se centra en caracterizar estadísticamente las 16 variables del conjunto de datos, identificar patrones relevantes, tratar valores faltantes implícitos y visualizar la relación entre las características y la variable objetivo: la suscripción de un depósito a plazo fijo. Se analizan distribuciones, medidas de tendencia central y dispersión, asimetría, curtosis y valores atípicos para las variables numéricas, así como frecuencias y tasas de suscripción para las variables categóricas. Como aplicación del análisis exploratorio, se entrenan dos modelos de clasificación supervisada —Regresión Logística y Random Forest— bajo configuraciones con y sin la variable *duration*, validando que las características identificadas durante la exploración efectivamente contribuyen a la predicción. Los hallazgos muestran que variables como *poutcome*, *month*, *job* y *balance* son los predictores más informativos en un escenario accionable.

Index Terms—análisis exploratorio de datos, estadística descriptiva, marketing bancario, visualización de datos, clasificación binaria, Random Forest, ciencia de datos

I. INTRODUCCIÓN

El análisis exploratorio de datos (EDA, por sus siglas en inglés) constituye una etapa fundamental en cualquier proyecto de ciencia de datos. Antes de construir cualquier modelo predictivo, comprender la estructura, distribución y relaciones entre las variables del conjunto de datos permite tomar decisiones informadas sobre el preprocesamiento, la selección de características y la elección de algoritmos [1].

El conjunto de datos *Bank Marketing* [3], recopilado de campañas de marketing telefónico de un banco portugués entre 2008 y 2013, representa un caso de estudio rico y desafiante: presenta desbalance de clases, variables categóricas con valores desconocidos, y una mezcla de características demográficas, financieras y de campaña. Estas características lo convierten en un escenario ideal para ilustrar técnicas de exploración y análisis estadístico aplicadas a problemas reales.

El problema de predicción subyacente —determinar si un cliente suscribirá un depósito a plazo fijo— es secundario al análisis exploratorio en este trabajo, y sirve principalmente

como marco de validación para los patrones identificados durante la exploración.

Objetivo del estudio

Realizar un análisis exploratorio completo del conjunto de datos *Bank Marketing*, caracterizando estadísticamente sus variables, identificando patrones y relaciones relevantes mediante visualizaciones, y validando los hallazgos a través de modelos de clasificación supervisada.

Organización del informe

La Sección II revisa trabajos relacionados. La Sección III constituye el núcleo del trabajo, con la descripción y análisis estadístico completo del conjunto de datos. La Sección IV describe brevemente la metodología de modelado. La Sección V presenta los resultados de los modelos como validación de los hallazgos exploratorios. La Sección VI expone las conclusiones y trabajos futuros.

II. ESTADO DEL ARTE

II-A. Análisis exploratorio en conjuntos de datos de marketing

El análisis exploratorio de datos en el contexto del marketing bancario ha sido señalado como una etapa crítica para entender el comportamiento del cliente. Moro et al. [2] demostraron que una cuidadosa selección de características basada en el análisis previo de importancia de variables permitió reducir el número de contactos necesarios en una campaña manteniendo altas tasas de éxito, subrayando el valor del EDA antes del modelado.

Chapman et al. [4] propusieron la metodología CRISP-DM, ampliamente adoptada en la industria, en la que el entendimiento y la exploración de los datos ocupan dos de las seis fases principales del proceso, evidenciando su centralidad en cualquier proyecto de ciencia de datos.

II-B. Trabajos que utilizan el conjunto de datos Bank Marketing

El conjunto de datos *Bank Marketing* es uno de los más referenciados en el repositorio UCI [3]. Ha sido ampliamente utilizado para comparar algoritmos de clasificación [6], estudiar el efecto del desbalance de clases, y como caso de uso en técnicas de explicabilidad como SHAP y LIME [7]. Estudios anteriores reportan ROC-AUC entre 0.75 y 0.93 dependiendo del conjunto de características utilizado, siendo los modelos de ensamble los que obtienen consistentemente mejores resultados [5].

III. DESCRIPCIÓN Y ANÁLISIS DEL CONJUNTO DE DATOS

III-A. Fuente y características generales

El conjunto de datos fue obtenido del repositorio UCI Machine Learning Repository [3]. Contiene **45,211 registros** y **17 variables**: 16 características de entrada y 1 variable objetivo (y), sin valores nulos explícitos.

III-B. Número y tipo de características

Las variables se clasifican según su naturaleza en tres grupos, como se muestra en la Tabla I.

Cuadro I
CLASIFICACIÓN DE VARIABLES DEL DATASET

Tipo	N	Variables
Numéricas continuas	5	age, balance, duration, campaign, pdays
Numéricas discretas	2	previous, day
Catóricas nominales	9	job, marital, education, default, housing, loan, contact, month, poutcome
Objetivo (binaria)	1	y (yes/no)

III-C. Estadística descriptiva de variables numéricas

La Tabla II resume las principales medidas estadísticas. Se incluyen medidas de posición (media, mediana), dispersión (desviación estándar, mínimo, máximo) y forma (asimetría y curtosis).

Cuadro II
ESTADÍSTICA DESCRIPTIVA EXTENDIDA DE VARIABLES NUMÉRICAS

Variable	Media	Mediana	D.E.	Mín.	Máx.	Asim.	Curt.
age	40.9	39.0	10.6	18	95	0.68	0.49
balance	1362	448	3044	-8019	102127	5.86	66.0
duration	258.2	180.0	257.5	0	4918	3.16	16.9
campaign	2.76	2.0	3.10	1	63	4.76	34.8
pdays	40.2	-1	100.1	-1	871	3.64	13.9
previous	0.58	0.0	2.30	0	275	18.3	581
day	15.8	16.0	8.32	1	31	0.09	-1.0

D.E. = Desviación Estándar; Asim. = Asimetría; Curt. = Curtosis.

Se destacan los siguientes hallazgos:

- **balance**: presenta la mayor asimetría positiva (5.86) y curtosis extrema (66.0), indicando la presencia de clientes con saldos muy elevados. La mediana (\$448) es muy inferior a la media (\$1,362), confirmando este sesgo.

- **duration**: alta asimetría positiva (3.16); la mayoría de llamadas son breves (mediana 180 s), pero existen casos extremos de hasta 4,918 segundos (~82 minutos).
- **campaign**: el número de contactos por campaña tiene mediana 2, pero puede llegar a 63, sugiriendo estrategias de contacto muy persistentes con algunos clientes.
- **pdays**: toma el valor -1 cuando el cliente no fue contactado previamente (81.7% de los casos), lo que distorsiona la media y requiere tratamiento especial.
- **previous**: altísima asimetría (18.3) y curtosis (581), producto de que la gran mayoría de clientes no había sido contactado antes.
- **day**: distribución aproximadamente uniforme (curtosis -1.0), indicando que los contactos se distribuyeron homogéneamente a lo largo del mes.

III-D. Detección de valores atípicos

Se aplicó el criterio del Rango Intercuartílico (IQR) para identificar valores atípicos. Un valor se considera atípico si cae por debajo de $Q_1 - 1.5 \cdot \text{IQR}$ o por encima de $Q_3 + 1.5 \cdot \text{IQR}$. Los resultados se muestran en la Tabla III.

Cuadro III
DETECCIÓN DE VALORES ATÍPICOS (CRITERIO IQR)

Variable	Outliers	%	Lím. inf.	Lím. sup.
age	280	0.62	9.5	71.5
balance	3 414	7.55	-3313	5385
duration	2 597	5.75	-446	847
campaign	2 396	5.30	-3 [†]	7
pdays	8 257	18.3	-1	-1
previous	2 394	5.30	-1 [†]	1
day	0	0.00	-9.5 [†]	40.5

[†] El límite negativo no aplica por definición de la variable.

balance concentra el mayor porcentaje de outliers reales (7.55 %), correspondientes a clientes con saldos muy elevados. Para pdays, el alto porcentaje se debe a que el valor -1 queda fuera del rango IQR por ser una codificación especial, no un valor atípico real.




Figura 1. Boxplots de variables numéricas. Se aprecian los valores atípicos en balance, duration y campaign.

III-E. Distribución de la variable objetivo

El conjunto de datos presenta un marcado **desbalance de clases**: el 88.3 % de los registros corresponde a clientes que no suscribieron (*no*) y el 11.7 % a quienes sí lo hicieron (*yes*). Este desbalance es representativo de situaciones reales en marketing directo y tiene implicaciones directas en la elección de métricas de evaluación.

III-F. Análisis de variables categóricas

La Tabla IV resume las frecuencias y tasas de suscripción de las variables categóricas más relevantes.

Cuadro IV
TASA DE SUSCRIPCIÓN POR CATEGORÍAS SELECCIONADAS

Variable	Categoría	Frecuencia (%)	Tasa suscrip. (%)
job	blue-collar	21.5	7.2
	management	20.9	13.5
	technician	16.8	10.5
	student	2.3	28.7
education	secondary	51.6	10.5
	tertiary	29.9	15.5
	primary	15.2	7.2
poutcome	success	3.4	64.7
	failure	10.8	13.0
	other	4.0	16.5
month	mar	1.3	51.4
	sep	2.1	44.6
	oct	1.8	43.5
	may	26.9	8.0

Los hallazgos más relevantes son:

- **poutcome = success**: clientes con campaña previa exitosa presentan una tasa de suscripción del 64.7 %, muy superior a la media del 11.7 %. Es el predictor categórico más potente.
- **job = student**: los estudiantes tienen una tasa de suscripción del 28.7 %, casi el triple de la media, posiblemente relacionado con incentivos de ahorro para jóvenes.
- **month**: los meses de marzo, septiembre y octubre presentan tasas superiores al 40 %, mientras que mayo —el mes con más contactos (26.9 %)— tiene solo un 8.0 %. Esto sugiere que la calidad del momento de contacto supera a la cantidad.
- **education = tertiary**: clientes con educación universitaria tienen mayor tasa de suscripción (15.5 %) respecto a los de educación primaria (7.2 %).




Figura 2. Tasa de suscripción por variable categórica.

III-G. Manejo de datos faltantes implícitos

El dataset no presenta valores NaN, pero tres variables categóricas contienen la categoría 'unknown' como valor faltante implícito (Tabla V).

Cuadro V
VARIABLES CON VALOR 'UNKNOWN'

Variable	Registros	Porcentaje
education	1857	4.11 %
contact	13020	28.79 %
poutcome	36959	81.75 %

La estrategia adoptada fue **reemplazar 'unknown' por la moda** de cada variable. Para poutcome, el alto porcentaje (81.75 %) se explica porque la mayoría de clientes no participó en campañas anteriores, por lo que este valor refleja información real y no ausencia de dato.

III-H. Selección de características

Se calculó la correlación de Pearson entre las variables numéricas y la variable objetivo binarizada. Los resultados se muestran en la Tabla VI.

Cuadro VI
CORRELACIÓN DE VARIABLES NUMÉRICAS CON LA VARIABLE OBJETIVO

Variable	Correlación con y
duration	0.395
pdays	0.103
previous	0.083
balance	0.052
day	0.030
age	0.030
campaign	-0.073

duration destaca con correlación de 0.395, sin embargo, es una variable **no accionable**: su valor se conoce solo al finalizar la llamada, por lo que no puede usarse para decidir a priori a quién contactar. Por este motivo se diseñaron dos experimentos: uno con duration (*benchmark*) y uno sin ella (escenario accionable).




Figura 3. Mapa de calor de correlaciones entre variables numéricas y la variable objetivo.

IV. METODOLOGÍA DE MODELADO

Como validación de los patrones identificados en el análisis exploratorio, se entrenaron modelos de clasificación supervisada. El preprocesamiento consistió en escalado estándar para variables numéricas y codificación one-hot para variables categóricas, implementados en un *pipeline* de scikit-learn. Los datos se dividieron en entrenamiento (60 %), validación (20 %) y prueba (20 %), con estratificación por clase. Se evaluaron dos modelos: **Regresión Logística** (con pesos balanceados) y **Random Forest** (250 árboles, pesos balanceados). El umbral óptimo se seleccionó maximizando el F1-score en validación. Dado el desbalance de clases, el **PR-AUC** fue la métrica principal de comparación.

V. RESULTADOS

V-A. Desempeño de los modelos

La Tabla VII resume el desempeño de los modelos, confirmando que las variables identificadas como relevantes durante el análisis exploratorio efectivamente contribuyen a la predicción.

Cuadro VII
RESULTADOS EN EL CONJUNTO DE PRUEBA

Experimento	Modelo	F1	Recall	Precisión	ROC-AUC	PR-AUC
Con duration	Random Forest	0.608	0.734	0.519	0.925	0.607
Con duration	Reg. Logística	0.579	0.721	0.484	0.907	0.536
Sin duration	Random Forest	0.480	0.507	0.457	0.799	0.448
Sin duration	Reg. Logística	0.441	0.453	0.430	0.771	0.408

V-B. Curvas ROC y Precisión-Recall

Las curvas ROC y Precisión-Recall confirman visualmente las diferencias entre modelos. En el escenario accionable (sin duration), el Random Forest obtiene mayor PR-AUC, validando que las características exploradas son informativas incluso sin la variable más correlacionada.




Figura 4. Curvas ROC y Precisión-Recall para los cuatro modelos evaluados.

VI. CONCLUSIONES Y TRABAJOS FUTUROS

VI-A. Conclusiones

Este trabajo realizó un análisis exploratorio completo del conjunto de datos *Bank Marketing*, revelando patrones estadísticamente relevantes sobre el comportamiento de los clientes bancarios. Las principales conclusiones son:

- Las variables numéricas presentan alta asimetría positiva, especialmente **balance** y **duration**, con presencia significativa de valores atípicos que deben considerarse en cualquier modelado posterior.
- El **resultado de la campaña anterior** (outcome = success) es el predictor más potente, con una tasa de suscripción del 64.7 %, seis veces superior a la media.
- El **mes de contacto** tiene un impacto mayor de lo esperado: contactar en marzo, septiembre u octubre duplica o triplica la tasa de éxito frente a mayo, el mes más activo en número de contactos.
- El desbalance de clases (11.7 % positivos) es el principal reto del dataset y debe abordarse mediante métricas y técnicas apropiadas como PR-AUC y pesos de clase balanceados.

- Los modelos de clasificación confirman que las variables identificadas como relevantes durante la exploración son efectivamente predictivas, validando el valor del análisis exploratorio previo al modelado.

VI-B. Trabajos futuros

- Aplicar técnicas de sobremuestreo (SMOTE) para mitigar el desbalance de clases.
- Explorar transformaciones de variables (logarítmica, raíz cuadrada) para reducir la asimetría de `balance` y `duration`.
- Incorporar métodos de explicabilidad (SHAP) para cuantificar la contribución de cada variable a las predicciones individuales.
- Evaluar modelos de mayor complejidad como Gradient Boosting (XGBoost, LightGBM).

AGRADECIMIENTOS

Los autores agradecen al repositorio UCI Machine Learning por la disponibilidad pública del conjunto de datos, y al docente Alain Alejo del curso MCD101 por las orientaciones metodológicas recibidas.

REFERENCIAS

- [1] J. W. Tukey, *Exploratory Data Analysis*. Reading, MA: Addison-Wesley, 1977.
- [2] S. Moro, P. Cortez y P. Rita, "A data-driven approach to predict the success of bank telemarketing," *Decision Support Systems*, vol. 62, pp. 22–31, jun. 2014. DOI: [10.1016/j.dss.2014.03.001](https://doi.org/10.1016/j.dss.2014.03.001)
- [3] S. Moro, P. Rita y P. Cortez, "Bank Marketing," UCI Machine Learning Repository, 2012. DOI: [10.24432/C5K306](https://doi.org/10.24432/C5K306)
- [4] P. Chapman *et al.*, "CRISP-DM 1.0: Step-by-step data mining guide," SPSS Inc., 2000. [En línea]. Disponible: <https://www.the-modeling-agency.com/crisp-dm.pdf>
- [5] C. Ferreira y A. Lopes, "Predicting bank telemarketing success with gradient boosting methods," *Journal of Business Analytics*, vol. 3, no. 2, pp. 98–110, 2020.
- [6] P. Bhatt, A. Bhatt y R. Singh, "Handling class imbalance in bank marketing dataset using SMOTE," *Proc. Int. Conf. Data Science*, pp. 145–152, 2020.
- [7] C. Molnar, *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*, 2.^a ed., 2020. [En línea]. Disponible: <https://christophm.github.io/interpretable-ml-book/>